

## Bootcamp Data Science - Ejercicio 14 - Gerardo Rodríguez

### 1. ¿Cuál es el concepto de aprendizaje profundo y cómo se relaciona con las redes neuronales?

El aprendizaje profundo o Deep learning, se inspira en las redes neuronales del cerebro, copiando la estructura de nodos para el procesamiento de datos de manera progresiva por diferentes etapas de proceso. Al generar varias capas de procesamiento, surge el nombre de redes neuronales profundas, ya que procesos que utilizan estas estructuras, requieren múltiples capas para procesos como procesamiento de imágenes y video, lenguaje natural, entre otros.

### 2. ¿Cuáles son algunas arquitecturas de aprendizaje profundo y ejemplos de aplicaciones?

#### A) Redes Neuronales Convolucionales (CNN):

Reconocimiento de imágenes (etiquetado automático de fotos en redes sociales), Detección de objetos, Segmentación semántica, Análisis de imágenes médicas para identificar patologías, Visión por computadora en vehículos autónomos (interpretar el entorno circundante)

#### B) Redes Neuronales Recurrentes (RNN):

Procesamiento de lenguaje natural (NLP, por sus siglas en inglés), Asistentes virtuales, Análisis de sentimientos, Reconocimiento de voz, Análisis de series temporales (precio de las acciones o la evaluación de patrones climáticos)

#### C) Long Short-Term Memory (LSTM) y Gated Recurrent Units (GRU):

Tareas de secuencias más complejas, como traducción automática, transcripción de voz a texto, y análisis de sentimientos.

#### D) Autoencoders:

Reducción de dimensionalidad, eliminación de ruido en imágenes (denoising), y generación de nuevas muestras similares a las de entrenamiento

#### E) Redes Adversarias Generativas (GAN):

Generación de imágenes, mejora de resolución de imágenes (super-resolución), transferencia de estilo, y simulación de datos

#### F) Transformers:

Traducción automática, clasificación de texto, generación de texto (como BERT y GPT).

### 3. ¿Qué son los modelos preentrenados y la transferencia de aprendizaje?

#### Modelos preentrenados:

Son modelos que ya han sido entrenados en un conjunto de datos grande y general, típicamente en tareas de gran escala como clasificación de imágenes en ImageNet.

Estos modelos ya han aprendido características relevantes de los datos, lo que les permite ser usados como punto de partida en tareas relacionadas, en lugar de entrenar un modelo desde cero.

#### Transferencia de aprendizaje:

Es una técnica en la que se toma lo que un modelo ha aprendido (por ejemplo, las características o patrones de un conjunto de datos) y se aplica o "transfiere" ese conocimiento a una nueva tarea.

Hay diferentes maneras de hacer transferencia de aprendizaje, como el uso de modelos preentrenados, finetuning, entre otros.

4. ¿Cuáles son algunos problemas comunes en el aprendizaje automático y cómo se pueden abordar?

Algunos problemas son el sobreajuste, el subajuste, falta de representatividad, y desequilibrio de datos. Se recomienda atender estos problemas de esta forma:

a) Sobreajuste

Regularización: Técnicas como L1 (Lasso) y L2 (Ridge) añaden una penalización a los modelos, lo que restringe la complejidad del modelo.

Pruning: En árboles de decisión, la poda implica eliminar subárboles que no proporcionan poder predictivo significativo.

Dropout: En redes neuronales, el dropout implica "apagar" aleatoriamente ciertas neuronas durante el entrenamiento, lo que previene dependencias excesivas en cualquier neurona particular.

Dividir el conjunto de datos en entrenamiento, validación y prueba, y monitorear el desempeño del modelo en la parte de validación para evitar que aprenda demasiado del conjunto de entrenamiento.

b) Subajuste

Utilizar modelos más complejos

Incorporar características adicionales

Incrementar la cantidad de datos de

Entrenamiento

Selección adecuada de modelos

c) Falta de representatividad

Recolectar datos de una variedad de fuentes y contextos, asegurándose de que todos los grupos de interés estén adecuadamente representados

d) Desequilibrio de datos

remuestreo:

sobremuestreando la clase minoritaria

submuestreando la clase mayoritaria

utilizar métricas de evaluación más robustas, como el área bajo la curva ROC (AUC-ROC), que son menos sensibles al desequilibrio de clases.

5. ¿Cuál es la importancia de la ética y la privacidad en el aprendizaje automático?

La importancia de la ética en el aprendizaje automático se refiere a la correcta aplicación de estos sistemas, asegurando que se utilicen de manera justa, transparente y sin causar daño.

Y en el caso de la privacidad se refiere a la protección de la información personal y a garantizar que los datos utilizados en el aprendizaje automático no se utilicen de manera indebida o sin el conocimiento y consentimiento de las personas involucradas.