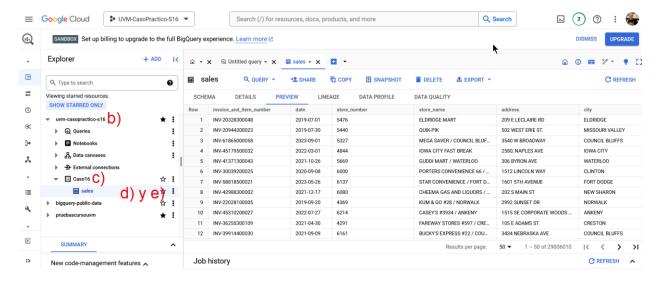
Bootcamp Data Science - Caso Práctico S16 - Gerardo Rodríguez.docx

Paso 1: Preparación del Dataset y Entorno de Trabajo

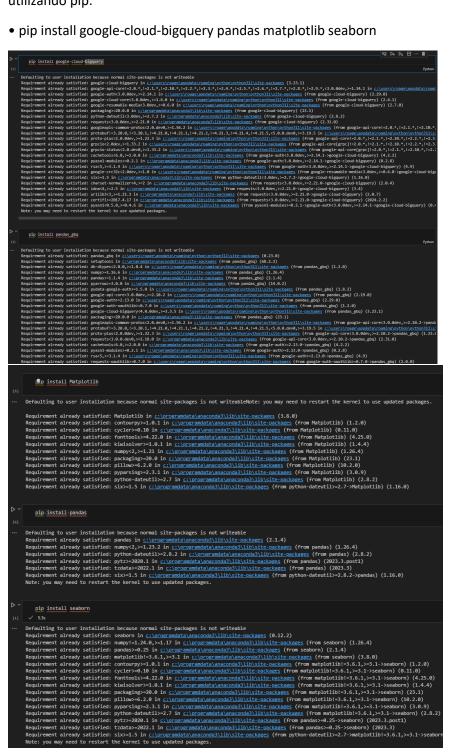
1. Agregar un Dataset y una tabla a BigQuery:

- a) Ve a la consola de Google Cloud.
- b) Crea un nuevo proyecto y navega a BigQuery.
- c) En el panel de recursos, crea un nuevo conjunto de datos.
- d) Carga un dataset público disponible en BigQuery o un dataset personal
- e) subiéndolo a tu espacio de trabajo.



2. Configurar el Entorno en VSCode:

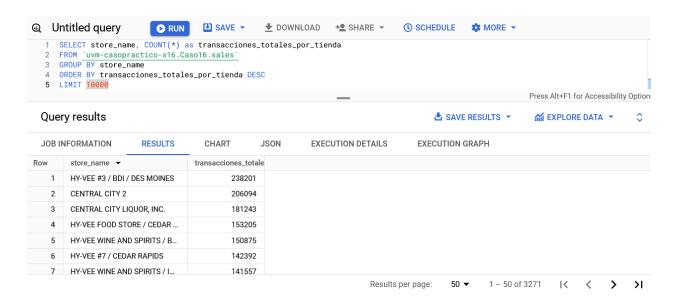
- Verificar tener las extensiones de Python, Jupyter y BigQuery para VSCode.
- Instala las bibliotecas necesarias, como google-cloud-bigquery y pandas, utilizando pip:
- pip install google-cloud-bigguery pandas matplotlib seaborn



Paso 2: Consultas SQL en BigQuery (Sugeridas: 2)

A continuación, se presentan 4 ejemplos de consultas a ejecutar en BigQuery:

a) Consulta de datos agregados	Transacciones totales por tienda
SELECT category, COUNT(*) as total_category	SELECT store_name, COUNT(*) as
FROM `project.dataset.table`	transacciones_totales_por_tienda
GROUP BY category	FROM `uvm-casopractico-s16.Caso16.sales`
ORDER BY total_category DESC	GROUP BY store_name
	ORDER BY transacciones_totales_por_tienda
	DESC
	LIMIT 10000



Se muestran las tiendas mostrando las transacciones que han entregado.

Se identifican 3271 tiendas diferentes.

```
b) Consulta de Datos con Filtro:

SELECT name, number

FROM `project.dataset.table`

WHERE number > 100.0

SELECT county, promventas_por_tienda

FROM (

SELECT county, SUM(sale_dollars) /

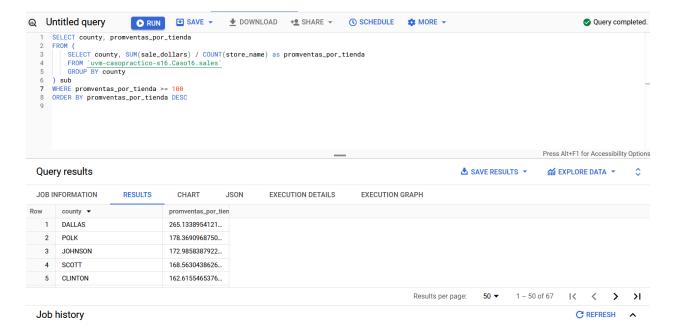
COUNT(store_name) as promventas_por_tienda

FROM `uvm-casopractico-s16.Caso16.sales`

GROUP BY county
) sub

WHERE promventas_por_tienda >= 100

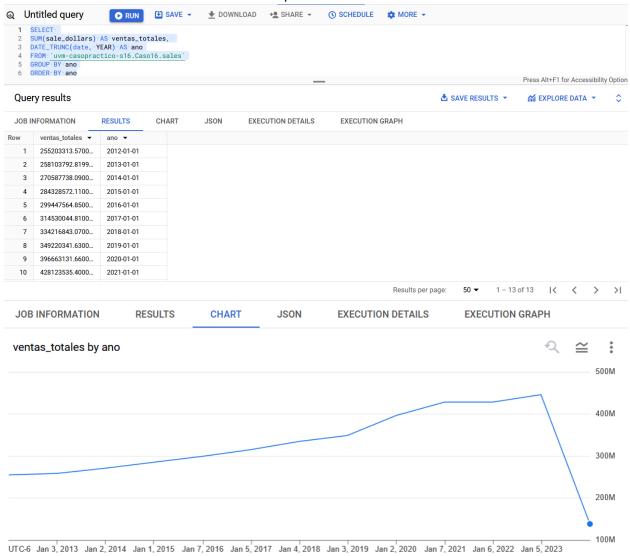
ORDER BY promventas_por_tienda DESC
```



Solo 67 de los 101 condados tienen un promedio de ventas por tienda superior a 100.

c) Consulta de Tendencias a lo Largo del Tiempo:	Sumatoria de las ventas totales por año
SELECT year, number	SELECT
FROM `project.dataset.table`	SUM(sale_dollars) AS ventas_totales,
GROUP BY year	DATE_TRUNC(date, YEAR) AS ano
ORDER BY year	FROM `uvm-casopractico-s16.Caso16.sales`
ONDER DI Yeur	GROUP BY ano
	ORDER BY ano

Se muestran la sumatoria de las ventas totales por año.



SELECT DATE_TRUNC(date, MONTH) as month, AVG(sales) as avg_sales FROM `project.dataset.table` GROUP BY month ORDER BY month

SELECT

DATE_TRUNC(date, MONTH) AS mes,

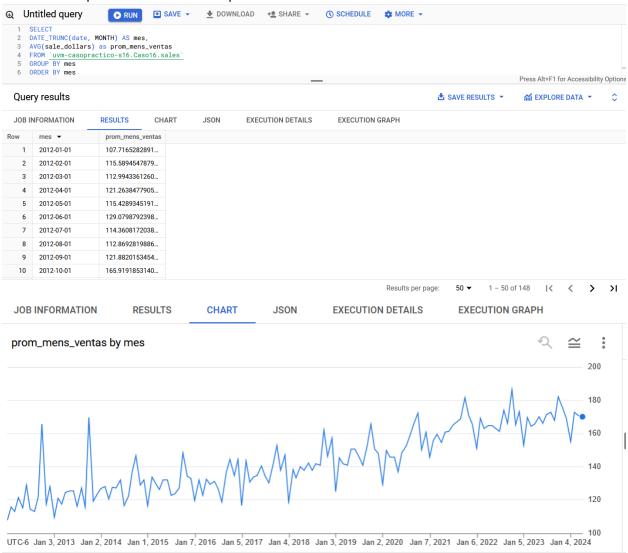
AVG(sale_dollars) as prom_mens_ventas

FROM `uvm-casopractico-s16.Caso16.sales`

GROUP BY mes

ORDER BY mes

Se muestra el promedio de las ventas por mes



Paso 3: Consultas SQL en Python (Sugeridas: 2, pueden ser las del paso anterior)

1. Conexión a BigQuery desde Python:

Crea un archivo Jupyter Notebook en VSCode.

Utiliza la biblioteca google-cloud-bigquery para conectarte a BigQuery y ejecutar tus consultas.

a) Cargamos localmente nuevo set de datos "Jugadores de Basketball" que consta de 4 tablas

```
import pandas as pd

df1 = pd.read_csv('players.csv')

df2 = pd.read_csv('players_teams.csv')

df3 = pd.read_csv('teams.csv')

df4 = pd.read_csv('awards_players.csv')

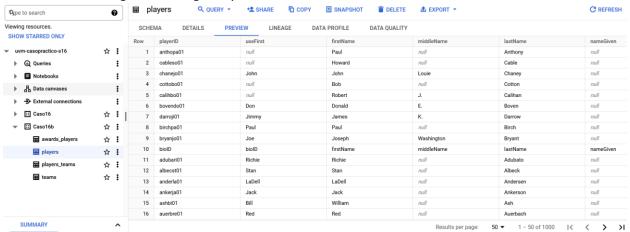
0.9s
```

b) Creamos nuevo proyecto y cuenta de servicio

c) Creamos conexión y subimos los archivos locales a BigQuery

```
# Generamos conexion a BO
   from google.oauth2 import service_account # para generar conexion
  bq_cred = service_account.Credentials.from_service_account_file('uvm-casopractico-s16-7619a96886b9.json')
   import pandas_gbq # para interactuar con BQ
  pandas_gbq.to_gbq(df1, 'Caso16b.players', project_id= 'uvm-casopractico-s16', if_exists= 'replace', credentials = bq_cred)
             | 1/1 [00:00<?, ?it/s]
   pandas_gbq.to_gbq(df2, 'Caso16b.players_teams', project_id= 'uvm-casopractico-s16', if_exists= 'replace', credentials = bq_cred)
100%
             | 1/1 [00:00<?, ?it/s]
   pandas_gbq.to_gbq(df3, 'Caso16b.teams', project_id= 'uvm-casopractico-s16', if_exists= 'replace', credentials = bq_cred)
   7.8s
              | 1/1 [00:00<?, ?it/s]
   pandas_gbq.to_gbq(df4, 'Caso16b.awards_players', project_id= 'uvm-casopractico-s16', if_exists= 'replace', credentials = bq_cred)
 √ 6.8s
100%
            | 1/1 [00:00<?, ?it/s]
```

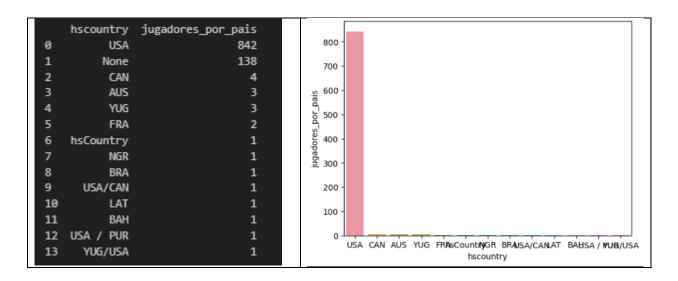
d) Validamos datos migrados en BigQuery



Paso 2: Consultas SQL en BigQuery (Sugeridas: 2)

A continuación, se presentan 4 ejemplos de consultas a ejecutar en BigQuery:

a) Consulta de datos agregados	Contar jugadores únicos por país
SELECT category, COUNT(*) as total_category	sql = """
FROM `project.dataset.table`	SELECT hscountry, COUNT(DISTINCT
GROUP BY category	<pre>playerID) as jugadores_por_pais</pre>
ORDER BY total_category DESC	FROM `uvm-casopractico-
	s16.Caso16b.players`
	GROUP BY hscountry
	ORDER BY jugadores_por_pais DESC
	<pre>df_bq = pd.read_gbq(sql,</pre>
	<pre>project_id='uvm-casopractico-s16',</pre>
	<pre>credentials = bq_cred,</pre>
	<pre>dialect='standard') #Dialect standard:</pre>
	para usar BigQuery's standard SQL
	dialect
	<pre>print(df_bq)</pre>



Se muestran los jugadores por país en la Base de datos, identificando que Estados Unidos es el que tienen más jugadores.

b) Consulta de Datos con Filtro:	Jugadores con mas de 2000 puntos
SELECT name, number FROM `project.dataset.table` WHERE number > 100.0	<pre>sql = """ SELECT tmID, playerid, MAX(points) AS MAYOR_PUNTAJE FROM `uvm-casopractico- s16.Caso16b.players_teams` WHERE points >= 2000 GROUP BY tmID, playerID ORDER BY MAYOR_PUNTAJE DESC """ df_bq = pd.read_gbq(sql, project_id='uvm- casopractico-s16', credentials = bq_cred, dialect='standard') #Dialect standard: para usar BigQuery's standard SQL dialect print(df_bq)</pre>
tmID playerid MAYOR_PUNTAJE 0 MIL abdulka01 2822 1 KCO archina01 2719	abdulka01
2 WAS arenagi01 2346 3 DAL aguirma01 2330 4 LAL abdulka01 2275	archina01
5 CIN archina01 2145 6 DEN anthoca01 2122	arenagi01
	aguirma01
	anthoca01
	0 500 1000 1500 2000 2500 MAYOR_PUNTAJE

Abdulka01 del equipo MIL es el jugador con mayor puntaje en la Base de datos.

c) Consulta de Tendencias a lo Largo del Tiem	oo: Jugadores con más de un premio por año
SELECT year, number	sql = """
FROM `project.dataset.table`	SELECT playerID, year, COUNT(playerID)
GROUP BY year	AS MVP
ORDER BY year	FROM `uvm-casopractico-
,	s16.Caso16b.awards_players`
	<u>—</u> .
	GROUP BY playerID, year
	HAVING COUNT(playerID) > 1
	ORDER BY year DESC;
	"""
	<pre>df_bq = pd.read_gbq(sql,</pre>
	<pre>project_id='uvm-casopractico-s16',</pre>
	<pre>credentials = bq_cred,</pre>
	<pre>dialect='standard') #Dialect standard:</pre>
	para usar BigQuery's standard SQL
	dialect
	<pre>print(df_bq)</pre>
	princ(dr_bq)
playerID year MVP	
0 jamesle01 2011 4	
1 irvinky01 2011 2	
2 chandty01 2011 3	
3 howardw01 2011 2	
4 bryanko01 2011 2	
 171 chambwi01 1965 2	
171 Chambwidi 1965 2 172 lucasje01 1963 2	
172 Ideas Jeol 1903 2 173 chambwi01 1959 3	
174 bayloel01 1958 2	
175 cousybo01 1956 2	
-	
[176 rows x 3 columns]	

Mostramos los jugadores con más premios agrupados por año.

```
Premios por año
sq1 = """
                                                          MVP
                                                     year
                                                 0
                                                     2011
                                                           30
SELECT year, COUNT(playerID) AS MVP
                                                 1
                                                     2010
                                                           27
FROM `uvm-casopractico-
                                                           30
                                                     2009
s16.Caso16b.awards players`
                                                     2008
                                                           27
GROUP BY year
                                                     2007
                                                           25
ORDER BY year DESC;
                                                 67 1942
                                                           1
                                                 68 1941
                                                           2
df bq = pd.read gbq(sql,
                                                    1939
project_id='uvm-casopractico-s16',
                                                 70 1938
                                                            1
credentials = bq_cred,
                                                 71 1937
dialect='standard') #Dialect standard:
                                                 [72 rows x 2 columns]
para usar BigQuery's standard SQL
dialect
print(df_bq)
# Para una serie temporal
import matplotlib.pyplot as plt
# Asegúrate de que 'year' y 'number' están en el formato correcto
# df['year'] debe ser de tipo datetime, para asegurarlos
df bq['year'] = pd.to_datetime(df_bq['year'], format='%Y')
# Asegúrate de que los datos están ordenados por 'year'
df bq = df bq.sort values('year')
# Crea la figura y el eje
plt.figure(figsize=(10, 5))
plt.plot(df_bq['year'], df_bq['MVP'], marker='', color='blue', linewidth=2)
# Título y etiquetas
plt.title('Serie de Tiempo de JAMES a través del tiempo')
plt.xlabel('year')
plt.ylabel('MVP')
# Mostrar la gráfica
plt.show()
                                    Premios Entregados por Año
             30
             25
             20
              15
             10
              5
```

1940

1950

1960

1970

1980

1990

2000

2010

```
d) Consulta de Datos Relacionales (Join):
                                            Lista de Jugadores por Equipo
                                            sql = """
SELECT a.name, b.purchase date, b.amount
FROM 'project.dataset.customers' a
                                            SELECT DISTINCT
JOIN 'project.dataset.purchases' b ON
                                              t.name,
a.customer_id = b.customer_id
                                              p.firstName,
                                              p.lastName
                                            FROM `uvm-casopractico-
                                            s16.Caso16b.players p
                                            JOIN `uvm-casopractico-
                                            s16.Caso16b.players_teams`pt
                                              ON p.playerID = pt.playerID
                                            JOIN `uvm-casopractico-
                                            s16.Caso16b.teams`t
                                              ON pt.lgID = t.lgID
                                            ORDER BY t.name, p.lastName
                                            df_bq = pd.read_gbq(sql,
                                            project id='uvm-casopractico-s16',
                                            credentials = bq_cred,
                                            dialect='standard') #Dialect standard:
                                            para usar BigQuery's standard SQL
                                            dialect
                                            print(df bq)
                             name firstName
                                             lastName
          Akron Firestone Non-Skids
                                      John
                                             Abramovic
         Akron Firestone Non-Skids
   1
                                    Howard
                                                Adams
         Akron Firestone Non-Skids Raymond
                                                Adams
   2
         Akron Firestone Non-Skids
                                    Glenn
   3
                                                Adams
   4
          Akron Firestone Non-Skids
                                    Willie
                                                Adams
   11289
                  Youngstown Bears
                                    Carl
                                                 Baer
   11290
                  Youngstown Bears
                                     Frank
                                                Baird
                                    Bob
   11291
                  Youngstown Bears
                                                Baker
   11292
                  Youngstown Bears
                                       Art Bakeraitis
   11293
                  Youngstown Bears Herbert
                                                 Ball
   [11294 rows x 3 columns]
```

Se muestra la lista de jugadores por equipo.